ALGORITMOS SUPERVISADOS ANTE “SYNTHETIC COFFE HEALTH”

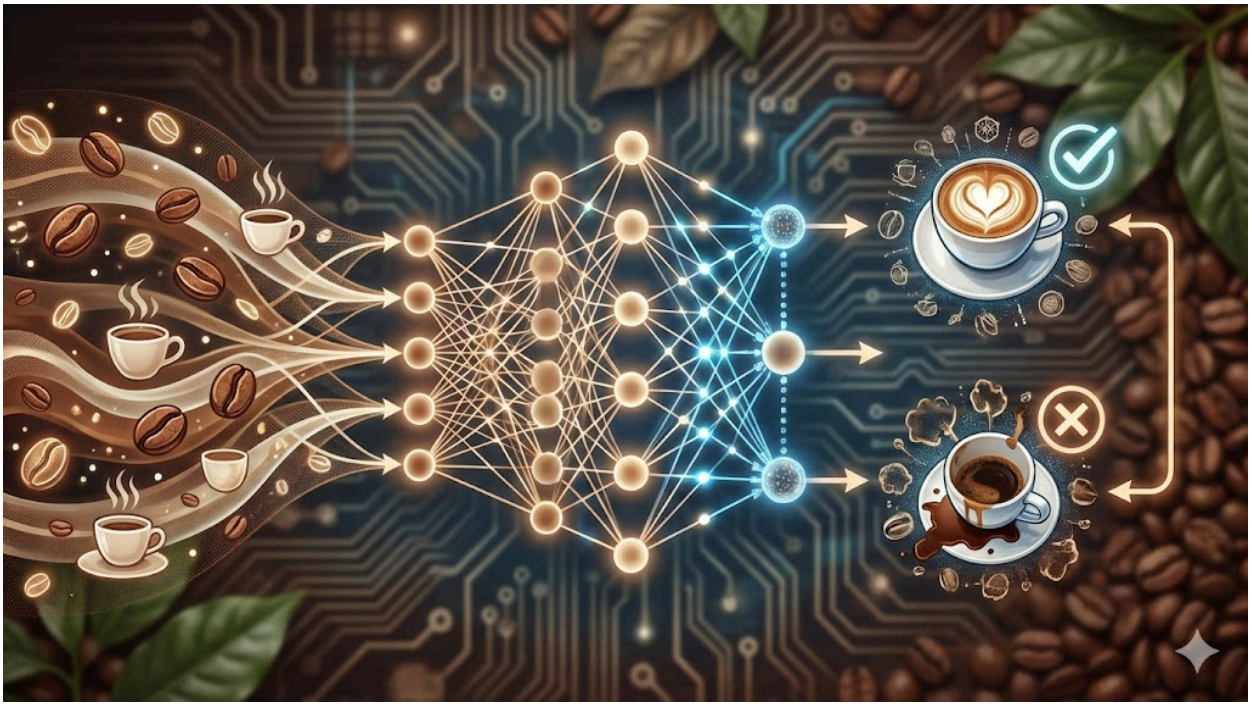

~ INTELIGENCIA ARTIFICIAL ~ PROYECTO #1

Realizado por:

- Luis Carmona Berdugo
- Alejandro Banda Remesal

1. Introducción y objetivos....3
1.1. Introducción y Objetivos....3
1.2 Estado del Arte....3
2. Descripción del Conjunto de Datos y Problema a Abordar....4
3. Preprocesamiento aplicado....5
3.1. Gestión de la Clase Objetivo y Binarización....5
3.2. Codificación de Variables Predictoras....5
3.3. División de Datos y Estandarización....6
4. Resultados y Comparativa....7
4.1. Análisis del Modelo de Regresión Lineal....7
Comparativa de Métodos de Optimización y Evaluación....7
4.2. Análisis de Modelos de Clasificación....8
Cálculo de Métricas y Tabla Comparativa....8
Análisis Detallado por Modelo....8
4.3. Gráficos....9
4.4. Conclusión y Discusión de Resultados....15
Modelo Ganador Global....15
Conclusión Final....16
5. Modificaciones....17
5.1. Análisis Univariable....17
5.2. Análisis de selección de atributos....19
5.3. Análisis de la tasa de aprendizaje....20
5.4. Análisis de la inicialización de los parámetros theta....23
5.5. Análisis del número de iteraciones....25

1. Introducción y objetivos

1.1. Introducción y Objetivos

Este trabajo se centra en el estudio de los fundamentos del Aprendizaje Automático Supervisado, una rama fundamental de la Inteligencia Artificial. Nuestro objetivo principal es aplicar estos conceptos implementando desde cero tres modelos clásicos: Regresión Lineal, Regresión Logística y una Red Neuronal Artificial.

Los objetivos específicos que nos planteamos son:

- Implementar la fase de entrenamiento y predicción de los tres modelos, incluyendo el cálculo y la visualización de la función de coste, así como las métricas de evaluación correspondientes.

- Entrenar y evaluar el rendimiento de los modelos sobre el conjunto de datos multivariable que se nos asignó.

- Comparar el desempeño de los modelos en las tareas de regresión y clasificación, realizando un análisis crítico de los resultados obtenidos.

- Aplicar las modificaciones solicitadas a uno de los modelos y analizar de manera justificada cómo estos cambios afectan su rendimiento y convergencia.

1.2 Estado del Arte

El uso del aprendizaje automático para analizar el estilo de vida y los riesgos para la salud, conocido como *Health Informatics*, es un campo que está creciendo rápidamente. La posibilidad de predecir resultados de salud o patrones de comportamiento, como el consumo de café, a partir de datos no clínicos ha ganado mucha relevancia en la última década.

Diversos estudios han empleado modelos de regresión para medir cómo variables como la ocupación o los hábitos de sueño afectan el consumo de cafeína. Asimismo, se ha demostrado que las redes neuronales artificiales son eficaces para la detección temprana de riesgos de salud, utilizando datos fáciles de obtener, como el IMC o los hábitos de vida. Por eso, nuestro trabajo no solo aplica los fundamentos teóricos del aprendizaje automático, sino que también se alinea con las tendencias actuales en el análisis predictivo de factores relacionados con el bienestar.

2. Descripción del Conjunto de Datos y Problema a Abordar

El conjunto de datos que utilizamos para este trabajo es *GlobalCoffeeHealth*, un repositorio con 10.000 registros sintéticos que reproducen patrones realistas de consumo de café, hábitos de sueño y resultados de salud.

Incluye información detallada sobre datos demográficos (edad, género, país), patrones de consumo (como *Coffee_Intake* o *Alcohol_Consumption*), métricas físicas (IMC, ritmo cardíaco) y factores de estilo de vida (horas de sueño, actividad física, nivel de estrés). La riqueza de las correlaciones que contiene lo hace ideal para realizar modelado predictivo en temas de bienestar y salud.

Para cumplir con los objetivos del enunciado, definimos dos problemas:

Problema de Regresión (Regresión Lineal)

- **Variable objetivo:** *Coffee_Intake* (consumo diario de café en tazas).

- **Justificación:** Elegimos el consumo diario de café como la variable a predecir porque no es un valor aleatorio, sino que se espera que esté influenciado por factores de estilo de vida, como el estrés, la ocupación o la calidad y duración del sueño. Predecir el patrón de consumo de cafeína de una persona a partir de estas variables nos ayuda a comprender la demanda de estimulantes y puede ser útil tanto para estudios de salud pública como para análisis de mercado.

Problema de Clasificación (Regresión Logística y Red Neuronal)

- **Variable objetivo:** *Health_Issues* (Problemas de salud: None, Mild, Moderate, Severe).

- **Justificación:** Seleccionamos *Health_Issues* como la variable de clase porque refleja el estado de salud de los participantes, determinado por factores como la edad, el IMC y el sueño. Clasificar a las personas en estas categorías de riesgo es clave para la medicina preventiva, ya que permite identificar perfiles con mayor probabilidad de desarrollar problemas de salud basándose únicamente en sus métricas de estilo de vida.

3. Preprocesamiento aplicado

Hemos realizado un preprocesamiento de los datos para adaptar el conjunto *Global Coffee Health* a los requerimientos matemáticos de los modelos, asegurando así que los resultados fueran estables y justos. Los pasos de preprocesamiento fueron básicamente los mismos para los tres pipelines (Regresión Lineal, Regresión Logística y Red Neuronal), aunque hubo pequeñas diferencias en cómo se codificaron algunas características.

3.1. Gestión de la Clase Objetivo y Binarización

Como los modelos de clasificación que usamos (Regresión Logística y Red Neuronal) son binarios por diseño o los adaptamos a un problema binario, transformamos la variable objetivo *Health_Issues* de la siguiente manera:

- **Clase 0 (Negativa):** Incluimos los registros donde *Health_Issues* era "None" (sin problemas de salud).

- **Clase 1 (Positiva):** Incluimos todos los demás casos ("Mild", "Moderate" y "Severe").

Esta binarización nos permite simplificar el problema a una pregunta clara: "¿Tiene la persona algún problema de salud o no?", facilitando la interpretación directa de la probabilidad que predicen los modelos.

3.2. Codificación de Variables Predictoras

Gestión de las características del modelo:

- **Variables ordinales:** Transformamos *Sleep_Quality* y *Stress_Level* usando un mapeo numérico (por ejemplo, Low = 0, Medium = 1, High = 2) para mantener la jerarquía que ya tenían estas categorías.

- **Variables nominales:** Codificamos *Gender* de dos maneras: con mapeo numérico para la Regresión Logística, y con One-Hot Encoding (OHE) para la Regresión Lineal y la Red Neuronal. Las columnas *Country* y *Occupation* las eliminamos en los modelos de Red Neuronal y Regresión Logística, mientras que en la Regresión Lineal codificamos *Country* con OHE para evitar demasiadas columnas y reducir el riesgo de sobreajuste.

- **Imputación:** En caso de valores faltantes en las columnas numéricas, los reemplazamos usando la media.

3.3. División de Datos y Estandarización

División de Datos (Holdout): Primero separamos nuestros datos usando el método Holdout: el 80% lo usamos para entrenar los modelos y el 20% restante para probarlos. Hicimos esta división antes de cualquier otra transformación para asegurarnos de que los datos de prueba se mantuvieran limpios y confiables.

Estandarización (Z-Score): Luego, estandarizamos todas las variables numéricas para que tengan media cero y desviación estándar uno. Esto es clave para que los algoritmos que usan gradientes, como el Descenso por Gradiente o el Backpropagation, funcionen mejor. Al poner todas las variables en la misma escala:

- Evitamos que los valores grandes, como *Caffeine_mg*, dominen sobre los pequeños, como *Smoking*.

- Hacemos que los modelos aprendan más rápido y sin saltos bruscos durante el entrenamiento.

4. Resultados y Comparativa

Esta sección evalúa el rendimiento de los modelos implementados en dos tareas distintas: Regresión (predicción continua de Coffee_Intake con Regresión Lineal) y Clasificación (predicción categórica con Regresión Logística y Red Neuronal).

4.1. Análisis del Modelo de Regresión Lineal

El modelo de Regresión Lineal se utilizó para predecir el Coffee_Intake.

Comparativa de Métodos de Optimización y Evaluación

Se comparan los métodos de optimización en el conjunto de prueba :

Método	MSE	MAE	MAPE
Descenso por Gradiente	3.0188	1.4009	1428783211.78%
Ecuación Normal	2.0579	1.1549	1427663811.55%

Hemos comprobado que como Coffe_Intake tiene valores a 0, el Mape se dispara y no tiene sentido el porcentaje que nos da.

Análisis de la Regresión Lineal:

1. **Ventaja de la Ecuación Normal:** La Ecuación Normal se muestra claramente como la mejor opción. Logra valores de MSE y MAE más bajos que el Descenso por Gradiente, lo que indica que encontró un mínimo más efectivo. El MAE de 1.15 significa que, en promedio, el modelo se equivoca en unas 1.15 tazas de café. Aunque el modelo refleja bastante bien la tendencia general, los errores residuales muestran que hay patrones no lineales que este modelo lineal simple no puede capturar.
2. **Conclusión principal:** La Regresión Lineal por sí sola no es suficiente para este problema. Aunque existe una relación lineal clara con la cafeína, hay interacciones y efectos no lineales que el modelo no puede considerar. Para predecir el consumo de café con mayor precisión, sería necesario usar un modelo más complejo, como una Red Neuronal o algún enfoque no lineal.

4.2. Análisis de Modelos de Clasificación

Ambos modelos se aplicaron a una tarea de clasificación binaria, categorizando una variable como Smoking o Health_Issues.

Cálculo de Métricas y Tabla Comparativa

Se calcula la Tasa de Acierto para ambos modelos de clasificación y estos son los resultados:

En ambos casos hemos utilizado 50 iteraciones para sacar los valores

Modelo	Verdaderos Positivos (TP)	Verdaderos Negativos (TN)	Falsos Positivos (FP)	Falsos Negativos (FN)	Total Muestras	Precisión(Tasa de Acierto)
Regresión Logística	688	1179	39	94	2000	93.35%
Red Neuronal	800	1184	8	8	2000	99.20%

Poniendo más interacción sabemos que regresión logística llega a un punto de estabilización en el mínimo global pero para compararlo con el modelo de Red Neuronal hemos optado por dejar ambas en 50 interacciones.

Análisis Detallado por Modelo

Red Neuronal

- **Precisión:** 99,20%
- **Ventaja:** Es nuestro modelo más potente en términos predictivos. La precisión extremadamente alta indica que la Red Neuronal ha aprendido una frontera de decisión no lineal capaz de separar las clases con muy pocos errores (solo 16 en el conjunto de prueba). La mínima diferencia con la precisión en entrenamiento (99,44%) descarta problemas de sobreajuste.
- **Inconveniente:** Su principal limitación es la falta de interpretabilidad. No podemos extraer directamente la importancia de cada característica, como sí lo hacemos con los coeficientes de un modelo lineal, para explicar los resultados.

Regresión Logística

- **Precisión :** 93,35%

- **Ventaja:** Su mayor fortaleza es la interpretabilidad. Al ser un modelo lineal, podemos entender cómo cada característica influye en la probabilidad de pertenecer a una clase, ofreciendo explicaciones claras de los fenómenos. Además, es un modelo estable y eficiente.

Inconveniente: Su rendimiento predictivo (93,35%) es claramente inferior al de la Red Neuronal (99,20%). La diferencia de casi 6 puntos porcentuales en precisión y los 133 errores de clasificación (39 falsos positivos + 94 falsos negativos) nos muestran que la Regresión Logística no puede capturar fronteras de decisión no lineales ni interacciones complejas, dejando margen para mejorar mediante un modelo más sofisticado.

4.3. Gráficos

Regresión Lineal

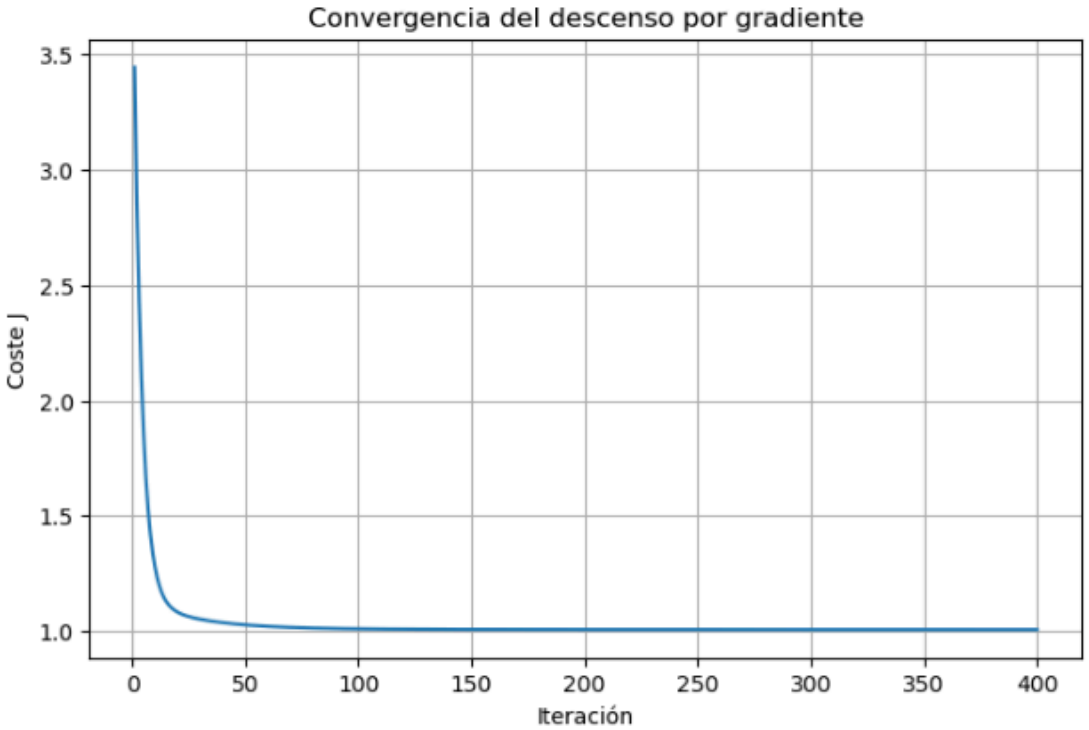

En lo relativo al modelo de Regresión Lineal, hemos observado una convergencia sólida y eficiente. Partiendo de un coste inicial elevado (~3.5), el algoritmo de Descenso por Gradiente logró reducir drásticamente el error en las primeras 100 iteraciones, demostrando una alta velocidad de aprendizaje para localizar el área del mínimo global. La posterior estabilización asintótica de la curva hasta la iteración 400 nos confirma que hemos alcanzado la solución óptima con un coste final mínimo (approx 1.0), validando el éxito del entrenamiento sin necesidad de extender el coste computacional innecesariamente.

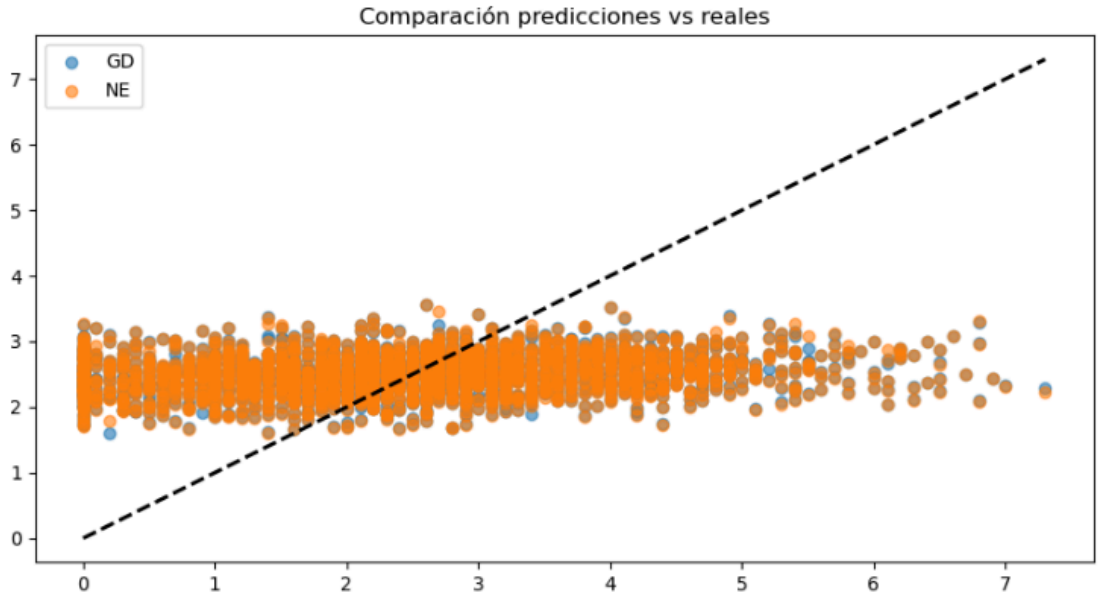

Al contrastar las predicciones con los valores reales, detectamos una limitación crítica: el modelo genera predicciones agrupadas en un rango muy estrecho, fallando en replicar la variabilidad real de la variable objetivo y desviándose de la diagonal de acierto. Esta tendencia a predecir valores casi constantes indica que el modelo subestima sistemáticamente el objetivo. Dicho comportamiento sugiere una relación lineal débil entre los predictores y la variable seleccionada, lo que invita a explorar modelos no lineales más complejos o a reconsiderar la idoneidad de la variable objetivo para este tipo de análisis.

Regresión Logística

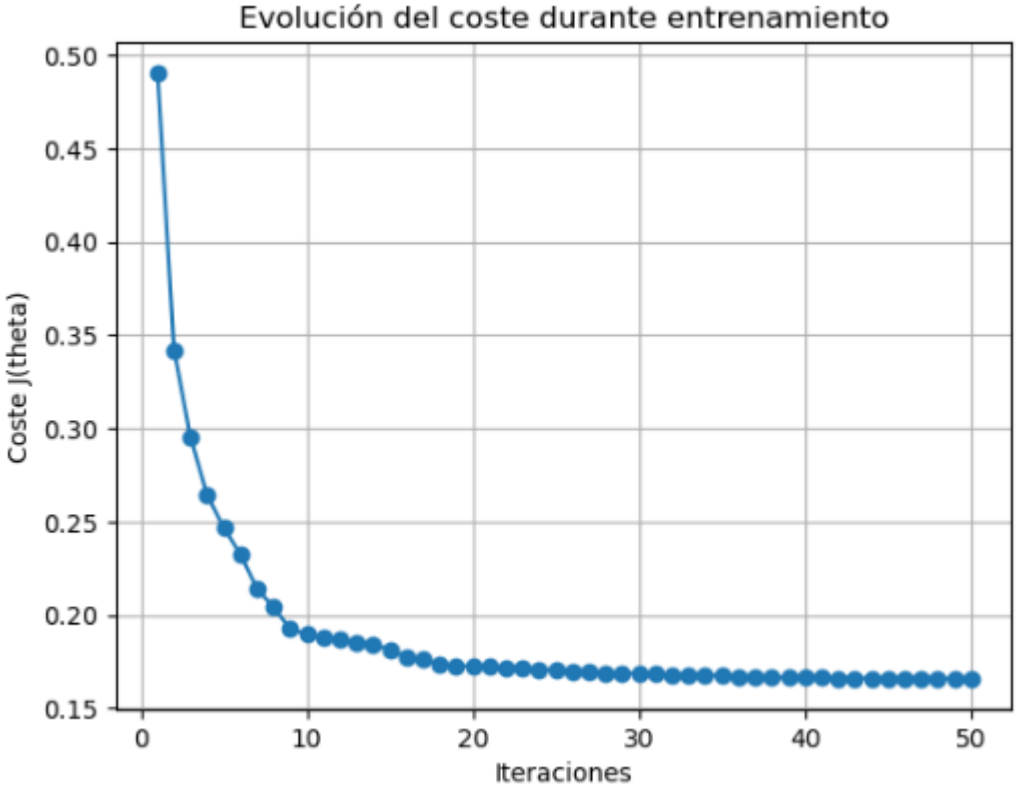

En la implementación de la Regresión Logística, la optimización mediante el método de Gradiente Conjugado (CG) ha demostrado ser altamente eficiente. Partiendo de un coste inicial cercano a 0.50, observamos un descenso drástico en las primeras 15 iteraciones, tras las cuales la curva se estabiliza asintóticamente en un valor final de 0.16. Este comportamiento confirma que el modelo logró capturar rápidamente los patrones discriminantes de los datos, alcanzando la convergencia al óptimo global con un coste computacional mínimo.

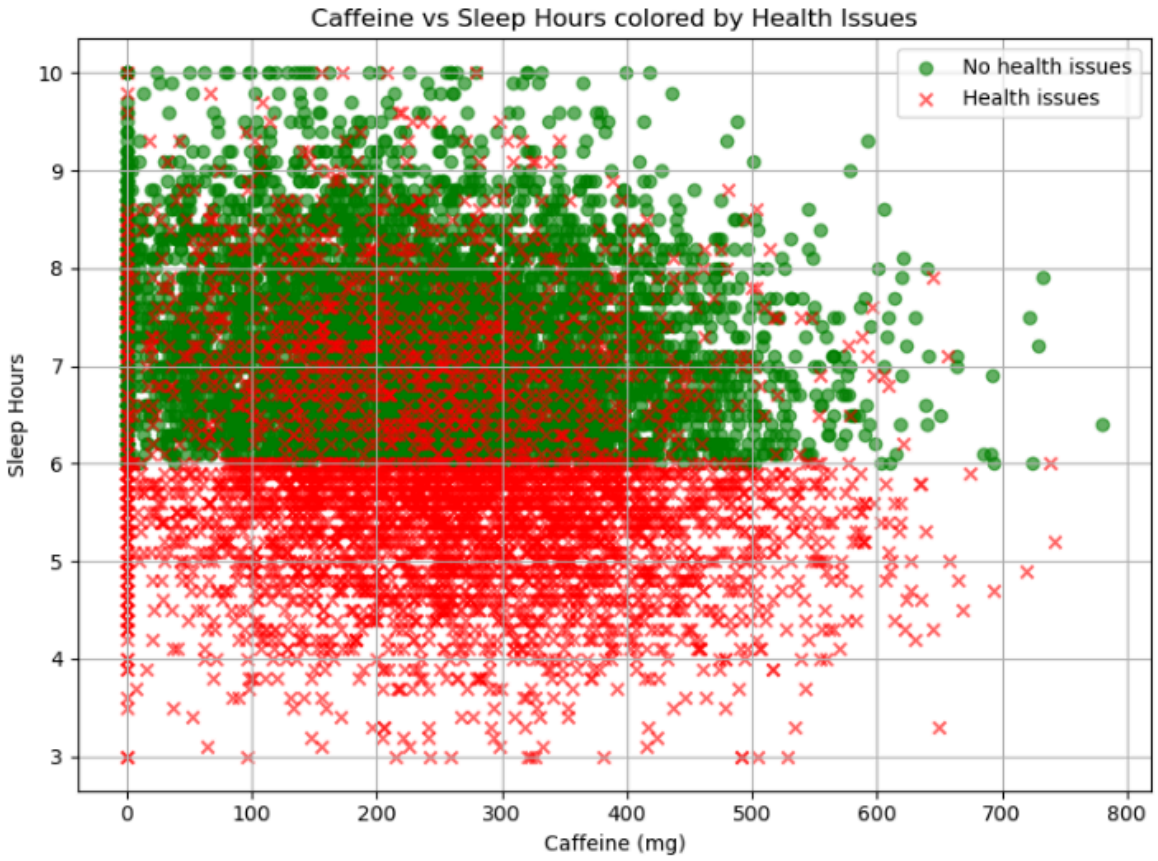

La representación gráfica de la relación entre el consumo de cafeína y las horas de sueño revela una clara separabilidad de clases impulsada primordialmente por la variable Sleep_Hours. Observamos que los casos con problemas de salud (rojo) se agrupan consistentemente en el rango inferior de horas de sueño (3-6h), mientras que los sujetos sanos (verde) predominan por encima de las 6 horas. El consumo de cafeína, aunque variable, presenta una mayor superposición entre clases, indicando un poder discriminante menor. Cabe mencionar que, al haber entrenado el modelo utilizando la totalidad de las características disponibles (multidimensional), la proyección de la frontera de decisión lineal exacta sobre este plano 2D resulta compleja y no representativa del hiperplano real de separación.

Redes Neuronales

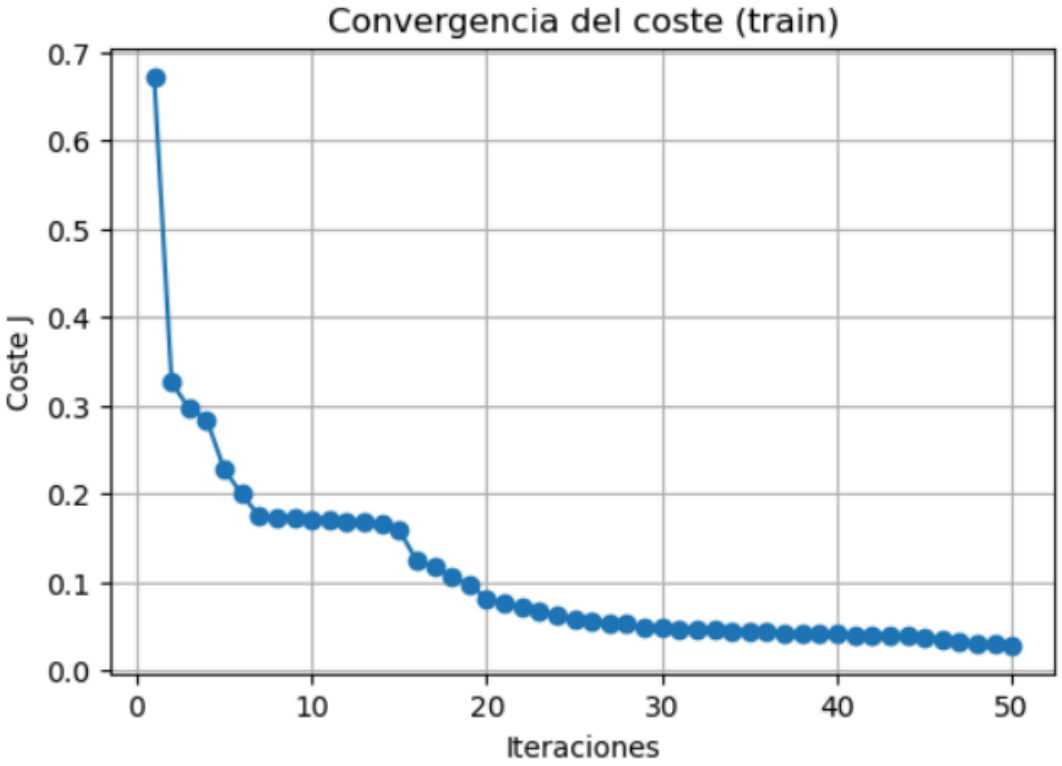

En el entrenamiento de la Red Neuronal, la curva de aprendizaje revela una optimización altamente eficiente. Partiendo de un coste inicial de ~0.67, observamos un descenso drástico del error en las primeras 10 épocas, logrando estabilizar la función de coste en un valor residual mínimo (approx 0.03) a partir de la iteración 25. Este comportamiento asintótico confirma que la red ha sido capaz de interiorizar las no linealidades subyacentes en los datos de manera rápida, alcanzando una convergencia robusta y profunda en tan solo 50 iteraciones.

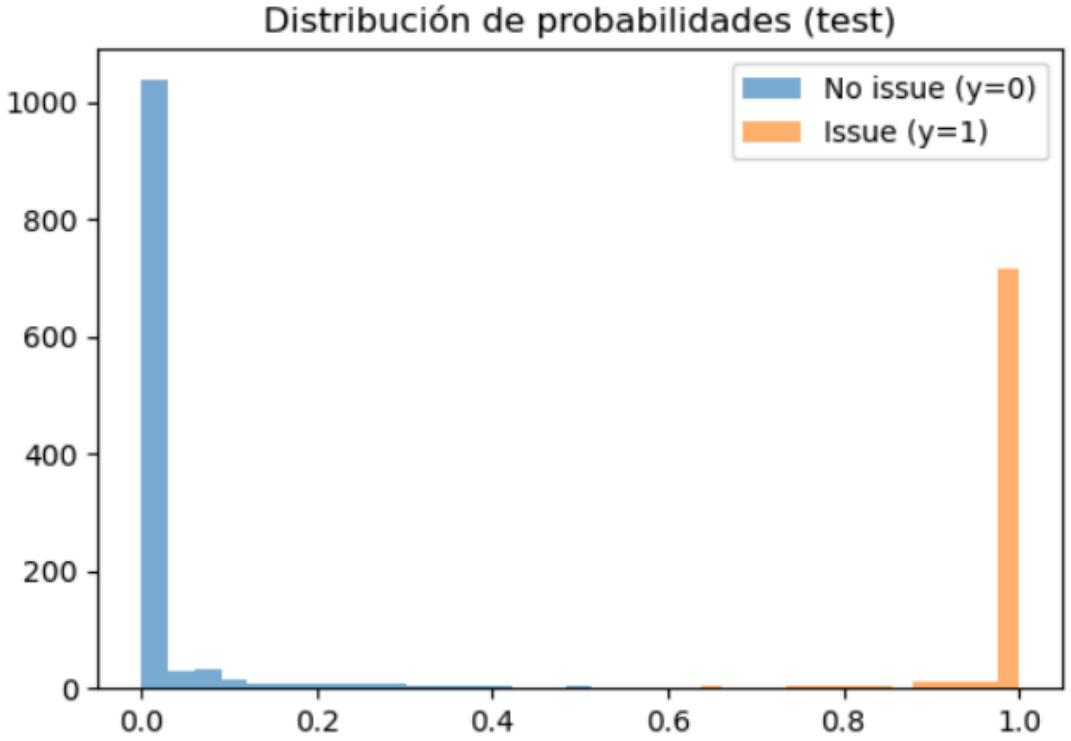

El análisis del histograma de probabilidades predichas revela una notable robustez en el modelo. Observamos una clara polarización de las predicciones hacia los extremos del intervalo 0.1, concentrándose la clase 'Sano' cerca de 0.0 y la clase 'Problema' cerca de 1.0. Esta ausencia de ambigüedad en torno a la frontera de decisión (0.5) indica que la red neuronal no solo clasifica correctamente, sino que opera con un alto grado de certidumbre. Dicha separación confirma la capacidad del modelo para extraer patrones discriminantes complejos, justificando directamente la elevada tasa de acierto (Accuracy) obtenida en la evaluación.

4.4. Conclusión y Discusión de Resultados

Modelo Ganador Global

Tarea	Modelo Ganador	Justificación
Regresión	Regresión Lineal (Ecuación Normal)	El modelo es nuestro mejor predictor lineal para esta tarea, con un MAE de 1,15 tazas. Sin embargo, no logra alcanzar una precisión predictiva alta, lo que indica que, para mejorar los resultados, sería necesario utilizar un enfoque no lineal.
Clasificación	Red Neuronal	Logramos la tasa de acierto más alta (99,20%), reduciendo al mínimo los errores de clasificación y demostrando que el modelo puede capturar fronteras de decisión complejas.

Ventajas e Inconvenientes

Modelo	Ventajas Clave	Inconvenientes Clave
Regresión Lineal	Ofrece alta interpretabilidad, es muy eficiente y proporciona un rendimiento excelente para predecir *Coffee_Intake*.	No logra capturar relaciones no lineales, y el Descenso por Gradiente presentó un rendimiento subóptimo.
Regresión Logística	Es fácil de implementar y permite interpretar los resultados directamente a través de sus coeficientes.	Menor precisión en clasificación que la Red Neuronal. Mayor tasa de falsos positivos y falsos negativos.
Red Neuronal	Logramos el máximo rendimiento predictivo (99,20% de Accuracy) gracias a su capacidad para capturar patrones no lineales.	Presenta baja interpretabilidad y requiere un mayor costo computacional.

Conclusión Final

Los resultados indican que la elección del modelo depende del objetivo que queramos alcanzar:

- **Interpretabilidad y regresión:** La Regresión Lineal es nuestro modelo más adecuado cuando queremos entender qué factores influyen de manera lineal en el consumo de café, especialmente la cantidad de cafeína, y además ofrece un error de predicción bajo.

- **Máximo rendimiento predictivo:** Para obtener la mejor precisión en la clasificación, la Red Neuronal es la opción ideal. Su mayor complejidad, que le permite capturar relaciones no lineales, se refleja en la reducción significativa de errores de clasificación, pasando de 129 en la Regresión Logística a solo 16 con la Red Neuronal.

Estos hallazgos muestran que, aunque el consumo de café se explica bien con un modelo lineal, la clasificación de riesgos de salud requiere un enfoque más sofisticado.

5. Modificaciones

5.1. Análisis Univariable

5.1.1. Variables independientes

Hemos seleccionado cuatro variables representativas de distintos aspectos fisiológicos y de estilo de vida:

- Sleep_Hours
- Stress_Level
- Age
- Hearth_rate

5.1.2. Comparación

Tras el entrenamiento de los modelos univariables, hemos evaluado el Error Cuadrático Medio (MSE), el coeficiente de determinación (R2) y la tendencia (Theta_Pendiente).

```
Tabla Comparativa Univariable (Ordenado por menor error):
       Variable       MSE        R2  Theta_Pendiente
0   Sleep_Hours  2.054821  0.037039        -0.273357
1  Stress_Level  2.091199  0.019991         0.217933
3    Heart_Rate  2.124852  0.004220         0.080272
2           Age  2.140991 -0.003343        -0.033365
```

5.1.3. Discusión

5.1.3.1. ¿Qué variable se comporta como mejor predictora?

Todas las variables presentan un R2 negativo, lo que indica que los modelos entrenados predicen peor un modelo que simplemente predijera la media aritmética. Aún así podemos concluir que el mejor modelo es el de Sleep_Hours, ya que su MSE es el más bajo, lo que ayuda a reducir el error cuadrático, que además es el más cercano a 0 siendo todos negativos.

5.1.3.2. ¿Por qué puede ocurrir esto?

La pendiente es negativa, lo que indica que a menor cantidad de sueño, mayor consumo de café. Dentro de la lógica humana podemos entender que el modelo captura el comportamiento de la cafeína en cuanto a la somnolencia.

Por otro lado aparece la variable Stress_Level en segundo lugar, con pendiente positiva, lo que sugiere que el estrés actúa como impulsor del consumo.

5.1.3.3. ¿Se observan relaciones lineales claras entre las variables?

Los signos de las pendientes discutidas son coherentes y distintos de cero, lo que indica que existe una tendencia real, es decir, el promedio varía con las variables de estrés y sueño. También se deduce con que las variables Hearth_Rate y Age no tienen ningún tipo de correlación con el consumo de café, ya que sus pendientes son muy cercanas a 0.
Volviendo al valor de R2 podemos deducir que un modelo lineal univariable en este caso no es suficiente para explicar la variabilidad de los datos en el conjunto de test. Como podemos ver en la captura, las nubes de puntos son muy dispersas y el error de predicción es alto en todos los casos.

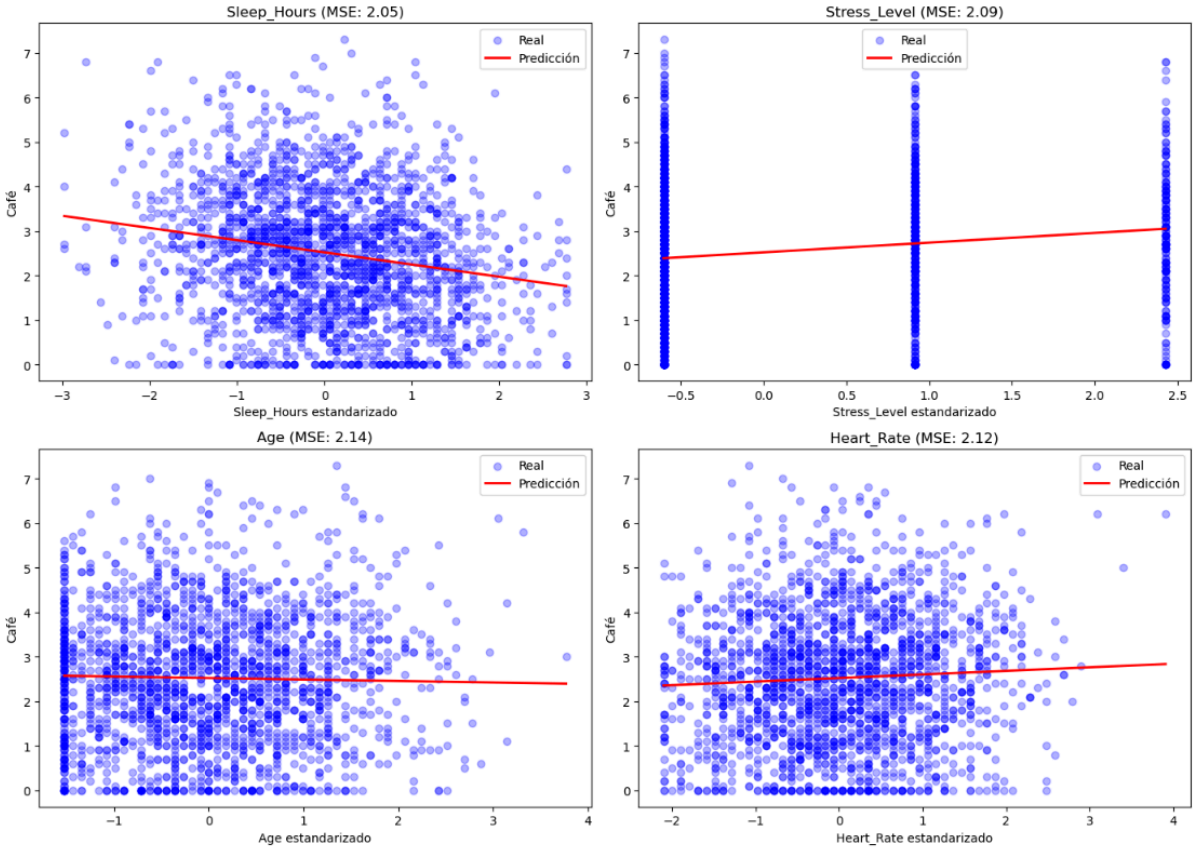

5.2. Análisis de selección de atributos

5.2.1. Selección de subconjuntos

Basándonos en los resultados del test univariable previo, donde Sleep_Hours y Stress_Level demostraron ser los predictores individuales más fuertes, vamos a definir tres escenarios de prueba. Con esto queremos evaluar el impacto de la dimensionalidad en rendimiento del modelo multivariable:

- Modelo Univariable: usando la mejor variable Sleep_Hours.
- Modelo Multivariable Reducido: usando las dos mejores Sleep_Hours y Stress_Level.
- Modelo Multivariable Completo: usando todas las variables disponibles en el dataset.

5.2.2. Discusión

5.2.2.1. ¿Con qué subconjunto de variables has obtenido el menor error?

Estos han sido los resultados obtenidos:

```
Tabla Comparativa de Selección de Atributos:
           Subconjunto  Num_Variables       MSE  Mejora vs Todas (%)
0  Solo Mejor Variable              1  2.054821            -0.007084
1      Top 2 Variables              2  2.054871            -0.009511
2  Todas las Variables             31  2.054675             0.000000
```

El subconjunto de todas las variables ha obtenido el mejor resultado con un MSE de 2,0546. Con esto podemos deducir que, a pesar de que Sueño y Estrés son factores dominantes, el resto de variables contienen también información valiosa para la predicción. La suma de estos aportes hace reducir el error cuadrático hasta en 0,0002 unidades con respecto a los modelos reducidos.

5.2.2.2. ¿Qué porcentaje de mejora se obtiene en el error con respecto al error cometido cuando se usan todas las variables?

Al comparar el modelo completo con el reducido obtenemos un porcentaje de mejora de -0,009%. Esto quiere decir que, como podemos ver también en el MSE, el rendimiento empeoró. Cabe resaltar que aunque tiene una pérdida de más del 0,008%, los modelos reducidos son capaces de alcanzar un rendimiento cercano al modelo completo. Esto sugiere que esas variables capturan la gran mayoría de la varianza explicable del problema.

5.3. Análisis de la tasa de aprendizaje

5.3.1. Entrenamiento con diferentes valore de la tasa de aprendizaje

Hemos decidido hacer la modificación del valor alpha de manera manual, capturando los resultados de cada una de las ejecuciones. Hemos mantenido fijas 400 iteraciones.

- 0.001

```
--- Dimensiones ---
Train: (8000, 31), Test: (2000, 31)

Coste inicial (train) con theta cero: 4.222896875000001
Theta (GD) primeros 5 valores:
 [ 7.90483928e-01 -1.06078046e-02 -7.03467610e-02 -7.12512838e-04
  2.52794575e-02]
```

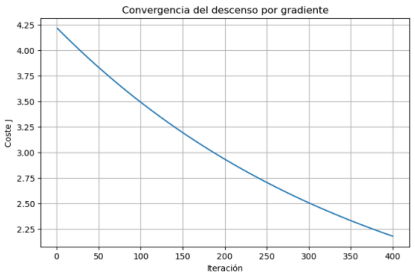


```
--- Métricas (test set) ---
Descenso por gradiente: MSE=4.2670, MAE=1.6782, MAPE=552818684.93%
Ecuación normal:        MSE=2.0579, MAE=1.1549, MAPE=1427663811.55%
```

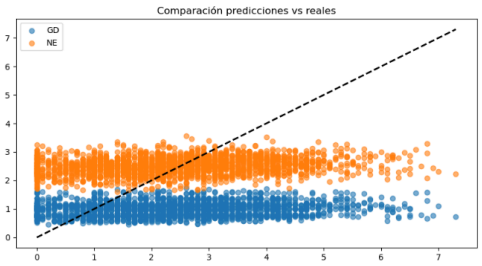


```
Predicción para el nuevo ejemplo:
 -> Descenso por gradiente: 1.32
 -> Ecuación normal:        2.50

Proceso finalizado.
```

- 0.01

```
--- Dimensiones ---
Train: (8000, 31), Test: (2000, 31)

Coste inicial (train) con theta cero: 4.222896875000001
Theta (GD) primeros 5 valores:
 [ 2.11566742e+00 -2.97094766e-02 -1.70014207e-01 -1.32411820e-03
  6.96851308e-02]
```

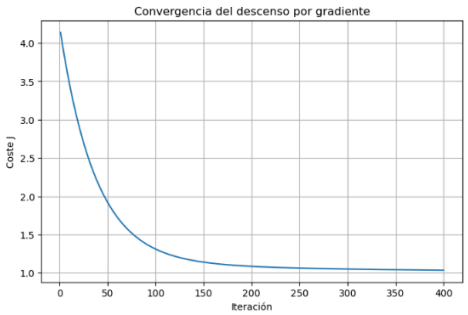


```
--- Métricas (test set) ---
Descenso por gradiente: MSE=2.1165, MAE=1.1731, MAPE=1382047218.59%
Ecuación normal:        MSE=2.0579, MAE=1.1549, MAPE=1427663811.55%
```

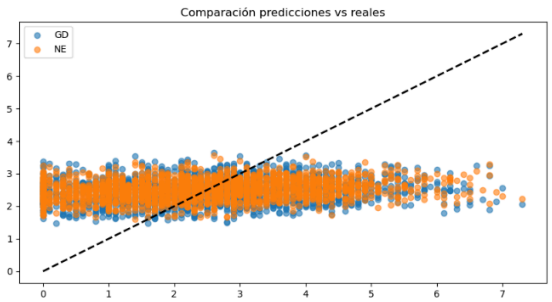


```
Predicción para el nuevo ejemplo:
 -> Descenso por gradiente: 2.78
 -> Ecuación normal:        2.50

Proceso finalizado.
```

- 0.1

```
--- Dimensiones ---
Train: (8000, 31), Test: (2000, 31)

Coste inicial (train) con theta cero: 4.222896875000001
Theta (GD) primeros 5 valores:
 [ 2.40345891e+00 -3.08606191e-02 -2.54849023e-01  1.30905090e-03
  7.14988502e-02]
```

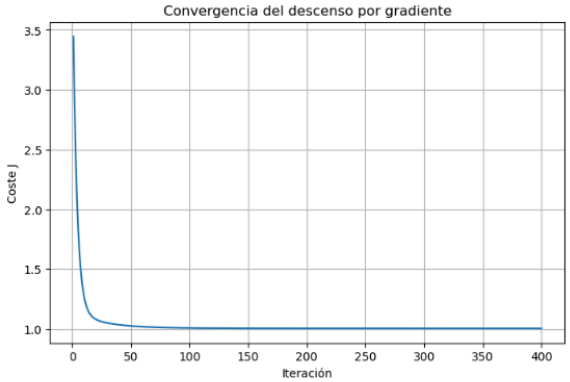


```
--- Métricas (test set) ---
Descenso por gradiente: MSE=2.0546, MAE=1.1545, MAPE=1427798000.66%
Ecuación normal:        MSE=2.0579, MAE=1.1549, MAPE=1427663811.55%
```

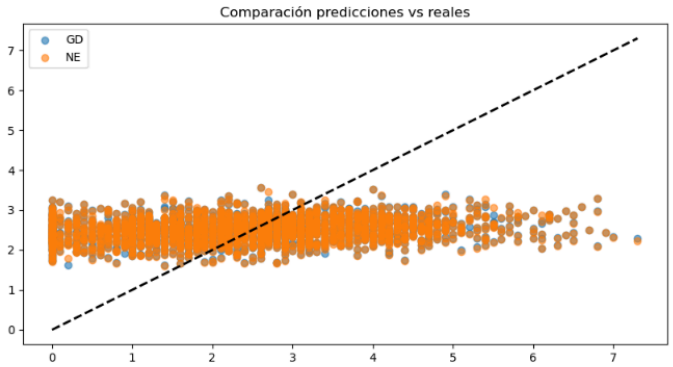


```
Predicción para el nuevo ejemplo:
 -> Descenso por gradiente: 2.51
 -> Ecuación normal:        2.50

Proceso finalizado.
```

- 1

```
--- Dimensiones ---
Train: (8000, 31), Test: (2000, 31)

Coste inicial (train) con theta cero: 4.222896875000001
Theta (GD) primeros 5 valores:
 [-1.73005303e+93  2.25404670e+94  1.54717688e+96  1.78073083e+94
 -7.27225689e+94]
```

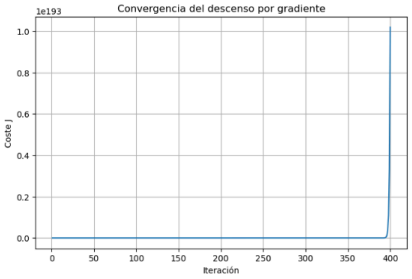


```
--- Métricas (test set) ---
Descenso por gradiente: MSE=20282269358238353466494786786988154934795665818490191818640702276670395683206891305903837997375776156735479371320668880065901142532949526840525880006288301205164384441477652220259840850657280000, MAE=369169981383742
85746028099780796108193721695108700308860066655486208173071624189833502099599528384.0000, MAPE=22057803948137638699787654389981285217946074342394565180671828185831400278877728169251723167245273556582400%
Ecuación normal:        MSE=2.0579, MAE=1.1549, MAPE=1427663811.55%
```

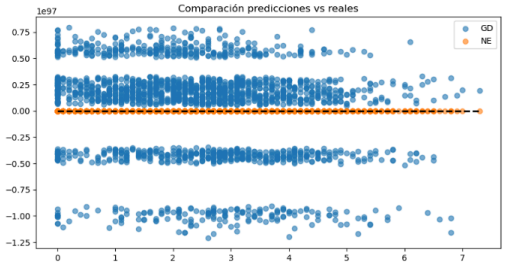


```
Predicción para el nuevo ejemplo:
 -> Descenso por gradiente: -40565199511474130116537101583679611069815346554892678958050756514275600327964241511541763033006 08.00
 -> Ecuación normal:        2.50

Proceso finalizado.
```

5.3.2. Convergencia de la función de coste

Podemos observar 4 comportamientos claramente diferenciados:

- 0.001: La convergencia es insuficiente, ya que la disminución del coste es extremadamente lenta, mostrando una trayectoria casi lineal. Al finalizar las iteraciones el valor del coste sigue siendo alto y la curva aún tiene una pendiente significativa.
- 0.01: Convergencia estable, ya que la curva desciende de forma suave y continua, es más lenta que 0.1, pero logra acercarse al mínimo al final de las 400 iteraciones.
- 0.1: Convergencia rápida, se observa una caída abrupta del coste en las primeras iteraciones, logrando estabilizarse en menos de una 50 iteraciones. La curva forma una "L" perfecta.
- 1: Divergencia, ya que la función no disminuye, sino que crece exponencialmente desde las primeras iteraciones.

5.3.3. Discusión

5.3.3.1. ¿Qué ocurre cuando la tasa de aprendizaje es demasiado baja?

Cuando es demasiado baja, 0.001, cómo hemos respondido en la cuestión anterior, los pasos del algoritmo en cada iteración son minúsculos.
Esto quiere decir que el modelo aprende, pero a una velocidad extremadamente lenta. Tras finalizar las 400 iteraciones el coste sigue descendiendo de forma casi lineal. Esto provoca una ineficiencia computacional, ya que se requerirían miles de iteraciones para alcanzar el mismo mínimo que un alpha óptimo logra en decenas.

5.3.3.2. ¿Y cuándo es demasiado alta?

Cuando la tasa es demasiado alta, 1, el tamaño del paso es superior a la distancia que falta para llegar al mínimo.
Debido a esto el algoritmo salta por encima del valle de la función de coste, cayendo en el lado opuesto en un punto más alto que el anterior, incrementando el error en vez de reducirlo.
Se produce por ello el fenómeno de divergencia.

5.3.3.3. Represente gráficamente la curva de error para cada valor y discuta la gráfica

Las gráficas se pueden visualizar en el apartado 5.3.1.

5.4. Análisis de la inicialización de los parámetros theta

5.4.1. Entrenamiento con distintas inicializaciones de los parámetros

De nuevo volvemos a hacer una ejecución para cada prueba con un alpha de 0.1 y 400 iteraciones fijas.

5.4.1.1. Todos ceros

```
--- Dimensiones ---
Train: (8000, 31), Test: (2000, 31)

Coste inicial (train) con theta cero: 4.222896875000001
Theta (GD) primeros 5 valores:
 [ 2.40345891e+00 -3.08606191e-02 -2.54849023e-01  1.30905090e-03
  7.14988502e-02]
```

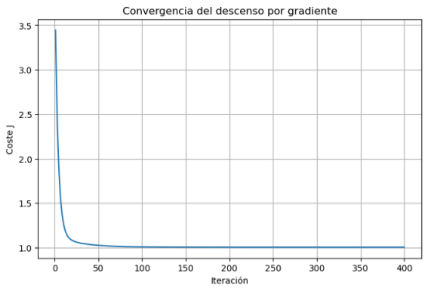


```
--- Métricas (test set) ---
Descenso por gradiente: MSE=2.0546, MAE=1.1545, MAPE=1427798000.66%
Ecuación normal:        MSE=2.0579, MAE=1.1549, MAPE=1427663811.55%
```

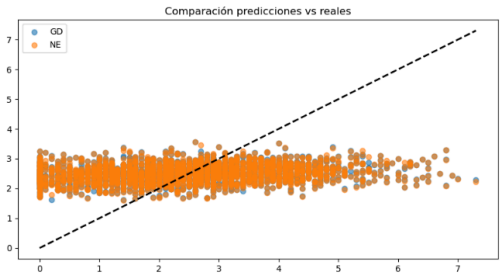


```
Predicción para el nuevo ejemplo:
 -> Descenso por gradiente: 2.51
 -> Ecuación normal:        2.50

Proceso finalizado.
```

5.4.1.2. Valores pequeños aleatorios

```
--- Dimensiones ---
Train: (8000, 31), Test: (2000, 31)

Coste inicial (train) con theta cero: 4.071114433620121
Theta (GD) primeros 5 valores:
 [ 2.39536730e+00 -3.07698520e-02 -2.50034089e-01  1.38567587e-03
  7.14861422e-02]
```

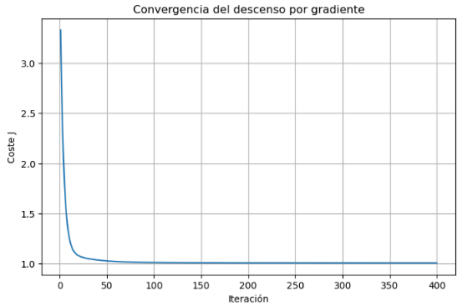


```
--- Métricas (test set) ---
Descenso por gradiente: MSE=2.0549, MAE=1.1545, MAPE=1427807852.67%
Ecuación normal:        MSE=2.0579, MAE=1.1549, MAPE=1427663811.55%
```

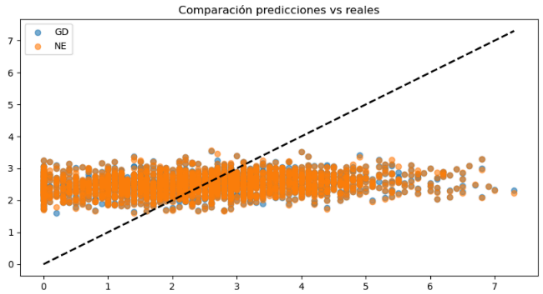


```
Predicción para el nuevo ejemplo:
 -> Descenso por gradiente: 2.52
 -> Ecuación normal:        2.50

Proceso finalizado.
```

5.4.1.3. Valores grandes aleatorios

```
--- Dimensiones ---
Train: (8000, 31), Test: (2000, 31)

Coste inicial (train) con theta cero: 141.2760494951534
Theta (GD) primeros 5 valores:
 [ 1.59429774 -0.02178391  0.22664439  0.00897155  0.07022805]
```

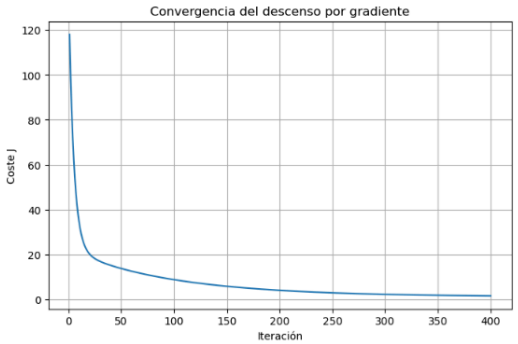


```
--- Métricas (test set) ---
Descenso por gradiente: MSE=3.0188, MAE=1.4009, MAPE=1428783211.78%
Ecuación normal:        MSE=2.0579, MAE=1.1549, MAPE=1427663811.55%
```

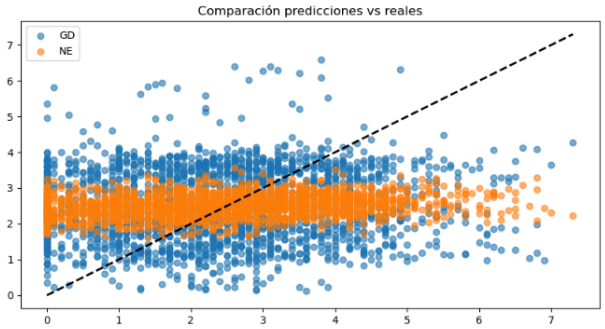


```
Predicción para el nuevo ejemplo:
 -> Descenso por gradiente: 2.82
 -> Ecuación normal:        2.50

Proceso finalizado.
```

5.4.2. Discusión

5.4.2.1. ¿Influye la inicialización en la convergencia del modelo?

Sí, influye en el punto de partida y en la trayectoria inicial, pero no impide la convergencia. Una inicialización con valores muy grandes provoca un coste inicial muy alto, como se observa en la última captura, sin embargo el modelo es capaz de recuperarse rápidamente de una mala inicialización y converge al mismo ritmo que los otros casos.

5.4.2.2. ¿Afecta al valor final del error o solo a la velocidad de aprendizaje?

No, afecta únicamente a la velocidad inicial de aprendizaje, pero no al valor final del error. Esto se debe a que la función de coste tiene forma de “cuenco”, con un único mínimo global y sin mínimos locales, por lo que da igual si empiezas en el fondo del cuenco (ceros) o en un borde muy alto (aleatorios grandes), siempre llevará los parámetros al mismo punto exacto, por lo que el MSE final será el mismo.

5.5. Análisis del número de iteraciones

5.5.1. Entrenamiento con distintos números de iteraciones

Para esta modificación hemos hecho varias ejecuciones con diferentes número de iteraciones en cada una. Sin embargo el alpha siempre ha sido 0.1 y el valor de thetas inicial 0.

- 100

```
--- Dimensiones ---
Train: (8000, 31), Test: (2000, 31)

Coste inicial (train) con theta cero: 4.222896875000001
Theta (GD) primeros 5 valores:
 [ 2.31011790e+00 -3.05936345e-02 -2.20242885e-01  4.86931141e-04
  7.12267324e-02]
```

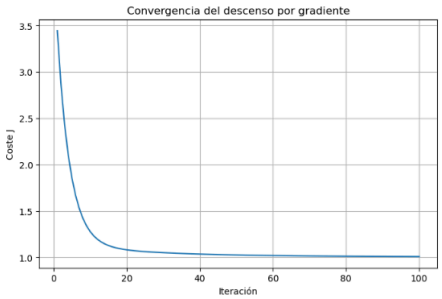


```
--- Métricas (test set) ---
Descenso por gradiente: MSE=2.0595, MAE=1.1570, MAPE=1417085390.06%
Ecuación normal:        MSE=2.0579, MAE=1.1549, MAPE=1427663811.55%
```

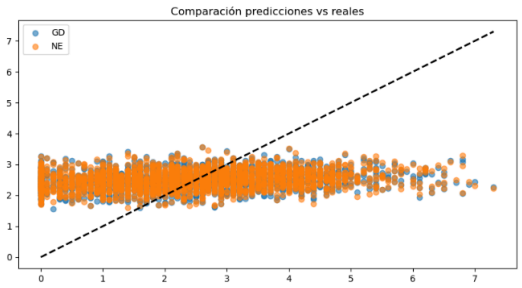


```
Predicción para el nuevo ejemplo:
 -> Descenso por gradiente: 2.59
 -> Ecuación normal:        2.50

Proceso finalizado.
```

- 500

```
--- Dimensiones ---
Train: (8000, 31), Test: (2000, 31)

Coste inicial (train) con theta cero: 4.222896875000001
Theta (GD) primeros 5 valores:
 [ 2.40835401e+00 -3.08813167e-02 -2.57028210e-01  1.31091975e-03
  7.15058579e-02]
```

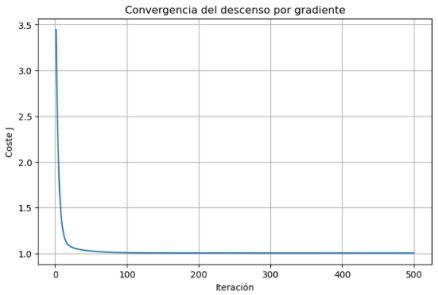


```
--- Métricas (test set) ---
Descenso por gradiente: MSE=2.0550, MAE=1.1544, MAPE=1427605341.83%
Ecuación normal:        MSE=2.0579, MAE=1.1549, MAPE=1427663811.55%
```

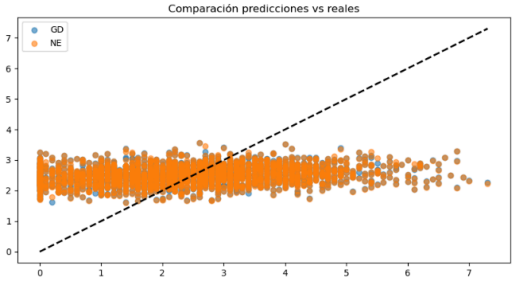


```
Predicción para el nuevo ejemplo:
 -> Descenso por gradiente: 2.51
 -> Ecuación normal:        2.50

Proceso finalizado.
```

- 1000

```
--- Dimensiones ---
Train: (8000, 31), Test: (2000, 31)

Coste inicial (train) con theta cero: 4.222896875000001
Theta (GD) primeros 5 valores:
 [ 2.42988157e+00 -3.09570881e-02 -2.60358983e-01  1.32952240e-03
  7.15268217e-02]
```

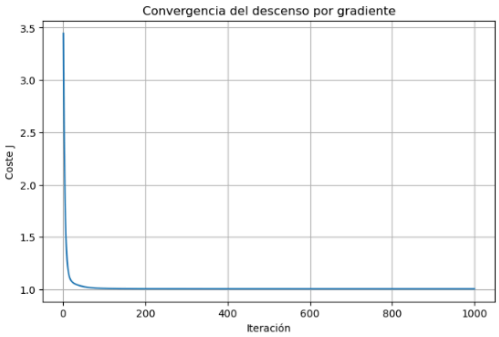


```
--- Métricas (test set) ---
Descenso por gradiente: MSE=2.0556, MAE=1.1545, MAPE=1427359813.31%
Ecuación normal:        MSE=2.0579, MAE=1.1549, MAPE=1427663811.55%
```

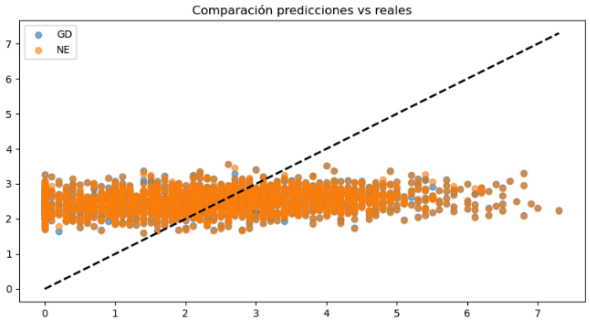


```
Predicción para el nuevo ejemplo:
 -> Descenso por gradiente: 2.51
 -> Ecuación normal:        2.50

Proceso finalizado.
```

- 5000

```
--- Dimensiones ---
Train: (8000, 31), Test: (2000, 31)

Coste inicial (train) con theta cero: 4.222896875000001
Theta (GD) primeros 5 valores:
 [ 2.53046795e+00 -3.12128152e-02 -2.61509450e-01  1.48748476e-03
  7.17384270e-02]
```

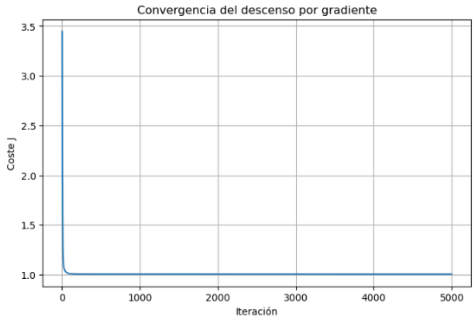


```
--- Métricas (test set) ---
Descenso por gradiente: MSE=2.0567, MAE=1.1547, MAPE=1427553963.98%
Ecuación normal:        MSE=2.0579, MAE=1.1549, MAPE=1427663811.55%
```

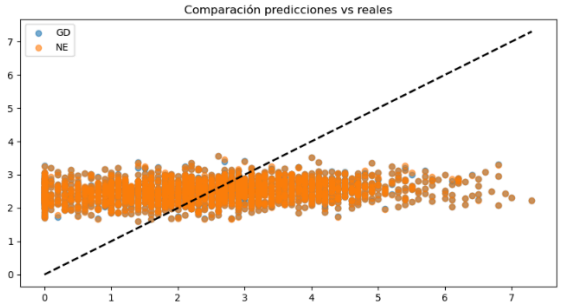


```
Predicción para el nuevo ejemplo:
 -> Descenso por gradiente: 2.51
 -> Ecuación normal:        2.50

Proceso finalizado.
```

5.5.2. Curva de aprendizaje

Quedan representadas las gráficas de la curva de aprendizaje en el apartado anterior.
Podemos observar como a las 100 iteraciones se produce una interrupción con una pendiente aún descendente, esto se corrige en las 500 iteraciones, ya que se observa la estabilización alcanzando el mínimo global del error.
Las iteraciones de 1000 y 5000 confirman esto mostrando una línea horizontal plana, demostrando que extender el entrenamiento más allá del punto de convergencia no aporta mejoras.

5.5.3. Discusión

5.5.3.1. ¿Cuándo se estabiliza la función de coste?

Observando la gráfica de 500 iteraciones podemos apreciar que la función de coste deja de disminuir de forma significativa alrededor de la iteración 150-200. A partir de ese punto la curva se vuelve plana, indicando que se ha alcanzado la zona del mínimo global.

5.5.3.2. ¿Qué ocurre si se entrena demasiado poco o demasiado tiempo?

Si se entrena demasiado poco se produce un desajuste, es decir, como hemos mencionado en apartados anteriores, el modelo cortó el aprendizaje antes de llegar al mínimo global. Esto lo podremos ver en la captura de 100 iteraciones.
Por otro lado, si se entrena demasiado, como en las capturas de 1000 o 5000, se produce una ineficiencia computacional. Esto quiere decir que el error no disminuye más, ya que hemos alcanzado el mínimo en muchas menos iteraciones de las realizadas.

5.5.3.3. ¿Se observan síntomas de sobreajuste?

No, el desajuste ocurriría si, al entrenar durante demasiado tiempo, el error de test empezará a subir. Pero podemos observar en la captura de 5000 iteraciones que el MSE se mantiene estable.